

INFERÊNCIA EM MODELOS LINEARES GENERALIZADOS

ANÁLISE DE DEVIANCE

- A análise de deviance é uma generalização, para modelos lineares generalizados, da análise de variância.
- No caso de modelos lineares, utiliza-se a chamada "extra soma de quadrados" para avaliar a significância de termos incluídos ao modelo;
- Em MLG, de forma semelhante, é de interesse testar a significância da inclusão de novos termos. Neste sentido, usaremos com frequência a expressão *modelos encaixados*;
- Dizemos que dois modelos são encaixados se um modelo é obtido a partir do outro impondo alguma restrição aos valores dos parâmetros (é usual assumir valor zero aos parâmetros, caso se deseje investigar a hipótese de nulidade dos mesmos);
- Na sequência são apresentados os preditores lineares de diferentes modelos lineares generalizados para avaliarmos se configuram modelos encaixados.

○ Caso 1:

$$\begin{array}{ll} \text{Modelo 1} - & g(\mu_{\mathbf{x}}) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 \\ \text{Modelo 2} - & g(\mu_{\mathbf{x}}) = \beta_0 + \beta_1 x_1 + \beta_3 x_3 \end{array} \quad \text{- Modelos encaixados!}$$

A comparação dois modelos apresentados no par 1 poderia fundamentar o teste da hipótese:

$$H_0 : \beta_2 = \beta_4 = 0,$$

contra a alternativa que os parâmetros sob teste não são conjuntamente nulos.

○ Caso 2:

$$\begin{array}{ll} \text{Modelo 1} - & g(\mu_{\mathbf{x}}) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 \\ \text{Modelo 2} - & g(\mu_{\mathbf{x}}) = \beta_0 + 2x_1 - x_3 + \beta_4 x_4 \end{array} \quad \text{- Modelos encaixados!}$$

A comparação dos dois modelos apresentados no par 2 poderia fundamentar o teste da seguinte hipótese:

$$H_0 : \beta_1 = 2; \beta_2 = 0; \beta_3 = -1.$$

○ Caso 3:

$$\begin{array}{ll} \text{Modelo 1} - & g(\mu_{\mathbf{x}}) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2 \\ \text{Modelo 2} - & g(\mu_{\mathbf{x}}) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 \end{array} \quad \text{- Modelos encaixados!}$$

A comparação dos dois modelos apresentados no par 3 poderia fundamentar o teste da seguinte hipótese:

$$H_0 : \beta_3 = 0.$$

Repare que, mediante este par de hipóteses, estaríamos testando a existência de interação entre x_1 e x_2 .

○ Caso 4:

$$\begin{array}{ll} \text{Modelo 1} - & g(\mu_{\mathbf{x}}) = \beta_0 + \beta_1 x_1 + \beta_2 x_1^2 + \beta_3 x_1^3 \\ \text{Modelo 2} - & g(\mu_{\mathbf{x}}) = \beta_0 + \beta_1 x_1 \end{array} \quad \text{Modelos encaixados!}$$

A comparação dos dois modelos apresentados no par 4 poderia fundamentar o teste da seguinte hipótese:

$$H_0 : \beta_2 = 0, \beta_3 = 0.$$

Repare que, mediante este par de hipóteses, estaríamos testando a existência de efeito cúbico ou quadrático de x_1 em y .

Nota – Note que em qualquer um dos quatro exemplos apresentados, a hipótese nula representa o modelo restrito e a hipótese alternativa o modelo não restrito. No contexto de teste de hipóteses, a rejeição de H_0 corresponde à diferença dos ajustes dos dois modelos, sendo que se deve optar, nesses casos, pelo modelo não restrito (com mais parâmetros).

○ Caso 5:

$$\begin{array}{l} \textit{Modelo 1} - \quad g(\mu_{\mathbf{x}}) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 \\ \textit{Modelo 2} - \quad g(\mu_{\mathbf{x}}) = \beta_0 + \beta_1 x_1 + \beta_4 x_4 \end{array} \quad \text{- Modelos não encaixados!}$$

○ Caso 6:

$$\begin{array}{l} \textit{Modelo 1} - \quad g(\mu_{\mathbf{x}}) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 \\ \textit{Modelo 2} - \quad g(\mu_{\mathbf{x}}) = \beta_0 + \beta_1 x_1 + \beta_2 \ln(x_2) \end{array} \quad \text{- Modelos não encaixados!}$$

Teste da razão de verossimilhanças (TRV) em MLG

- O teste da razão de verossimilhanças é amplamente utilizado em MLG para testar a nulidade conjunta de (ou alguma outra restrição envolvendo) parâmetros de modelos lineares generalizados.
- Seja M_p um MLG com p parâmetros e M_q um modelo encaixado a M_p , a partir de uma restrição a $p - q$ parâmetros, restando $q < p$ parâmetros não fixados (irrestritos).
- Considere D_p e D_q , respectivamente, os desvios de M_p e M_q . A estatística é uma medida de diferença dos ajuste de M_p e M_q , que pode ser entendida como o ganho de ajuste decorrente da inclusão de $p - q$ parâmetros ao modelo mais simples.

- A estatística do teste da razão de verossimilhanças para comparação dos dois modelos fica dada por:

$$\xi_{RV} = \frac{D_q - D_p}{\phi} = 2\phi^{-1} \{l(\hat{\mu}_p; \mathbf{y}) - l(\hat{\mu}_q; \mathbf{y})\} = 2\phi^{-1} \left\{ \ln \left[\frac{L(\hat{\mu}_p; \mathbf{y})}{L(\hat{\mu}_q; \mathbf{y})} \right] \right\},$$

que, sob a hipótese nula de que as restrições são válidas, tem **assintoticamente** distribuição χ^2_{p-q} .

- Caso a hipótese nula seja de nulidade de $p - q$ parâmetros e o resultado do teste indique a não rejeição de H_0 , isso pode justificar a eliminação dos termos (covariáveis, fatores...) associados aos $p - q$ parâmetros ‘nulos’.

Nota – O teste da razão de verossimilhanças pode ser aplicado a um único parâmetro (Exemplo: $H_0 : \beta_k = 0$ vs $H_1 : \beta_k \neq 0$), sendo que neste caso, sob H_0 ξ_{RV} tem, assintoticamente, distribuição χ^2_1 .

Nota – Podemos testar a significância do modelo ajustado considerando a hipótese nula $H_0 : \beta_1 = \beta_2 = \dots = \beta_{p-1} = 0$, ou seja, comparando o ajuste do modelo com p parâmetros ao do modelo nulo (só com intercepto).

No R:

```
ajuste1=glm(...)### "Modelo maior"  
ajuste2=glm(...)### "Modelo menor"  
anova(ajuste2,ajuste1,test='Chisq')
```

Procedimento geral para o teste da razão de verossimilhanças em Modelos Lineares Generalizados

1. Formular as hipóteses de interesse e estabelecer adequadamente os modelos restrito (M_q) e não restrito (M_p) correspondentes;
2. Ajustar os dois modelos aos dados e extrair os correspondentes desvios (D_q e D_p);
3. Calcular a estatística do teste da razão de verossimilhanças (ξ_{RV});
4. Com base no valor de ξ_{RV} , testar a hipótese nula de que a restrição considerada é válida. Por exemplo, para um nível de significância α , rejeitamos H_0 se ξ_{RV} exceder o quantil $(1-\alpha)$ da distribuição χ^2_{p-q} .

Teste F para o caso em que ϕ é desconhecido

- Para as distribuições em que o parâmetro de dispersão é desconhecido (Normal, Gama e Normal Inversa, por exemplo), pode-se utilizar uma estimativa e considerar como alternativa o uso do teste F , ao invés de χ^2 .
- A estatística do teste F é definida por:

$$\xi_{RV} = \frac{(D_q - D_p)/(p - q)}{D_p/(n - p)},$$

que, sob a hipótese nula de que as restrições impostas em H_0 são válidas, tem **assintoticamente** distribuição $F_{p-q, n-p}$.

Nota – Pode-se substituir $D_p/(n-p)$ no denominador da estatística F por alguma estimativa consistente de ϕ .

No R:

```
ajuste1=glm(...)### "Modelo maior"  
ajuste2=glm(...)### "Modelo menor"  
anova(ajuste2,ajuste1,test='F')
```

Análise de deviance desvio (Tabela ANODEV)

- A análise de deviance configura uma extensão da análise de variância para os modelos lineares generalizados.
- Baseia-se na comparação das deviances avaliadas para modelos encaixados, permitindo testar o efeito de sucessivas inclusões inclusão (ou exclusões) de variáveis, fatores e interações a um modelo corrente.
- A Tabela Anodev é a representação de uma sequência de TRVs para um modelo linear generalizado, em que os termos do preditor linear são acrescentados sucessivamente ao modelo (começando pelo modelo nulo), e a significância de suas inclusões avaliadas via TRV.

- A título de ilustração, considere um MLG qualquer, com quatro variáveis no preditor linear (X_1, X_2, X_3, X_4). Então, na tabela Anodev serão apresentados os desvios, as diferenças de deviances, os correspondentes graus de liberdade e os testes de razão de verossimilhança para:
 - Inclusão de X_1 ao modelo que contém apenas o intercepto;
 - Inclusão de X_2 ao modelo que contém X_1 ;
 - Inclusão de X_3 ao modelo que contém X_1 e X_2 ;
 - Inclusão de X_4 ao modelo que contém X_1, X_2 e X_3 .

Notas-

1. A ordem de inclusão das variáveis é determinada pelo usuário e, exceto em casos bem específicos, vai alterar a significância das variáveis;
2. A ordem de inclusão de termos ao modelo, quando na ocorrência de interações, deve obedecer ao *princípio hierárquico*. Ou seja, se temos no modelo X_1, X_2 e $X_1 \times X_2$, primeiramente inserimos ao modelo X_1 e X_2 (na ordem que bem se entender) para **depois** inserir o termo correspondente à interação. O mesmo vale para modelos polinomiais, em que os termos de menor ordem são os primeiros a serem inseridos.

No R: Comando `anova`.

- Uma forma alternativa de se fazer a análise do desvio é avaliando a significância de uma variável quando inserida ao modelo que contém todas as demais variáveis, exceto a variável em questão.
- A título de ilustração, considere um MLG qualquer, com quatro variáveis no preditor linear (X_1, X_2, X_3, X_4). Então, na tabela Anodev serão apresentados os desvios, as diferenças de deviances, os correspondentes graus de liberdade e os testes de razão de verossimilhança para:
 - Inclusão de X_1 ao modelo que contém X_2, X_3 e X_4 ;
 - Inclusão de X_2 ao modelo que contém X_1, X_3 e X_4 ;
 - Inclusão de X_3 ao modelo que contém X_1, X_2 e X_4 ;
 - Inclusão de X_4 ao modelo que contém X_1, X_2 e X_3 .

No R: Comando Anova, pacote car.

Teste de Wald

- O teste de Wald baseia-se na distribuição assintótica normal dos estimadores de máxima verossimilhança dos parâmetros do modelo.
- Seja $\hat{\beta}_j$ o estimador de máxima verossimilhança de β_j , um particular parâmetro de um MLG. Conforme discutido anteriormente, para $n \rightarrow \infty$,

$$\hat{\beta}_j \sim Normal(\beta_j, Var(\hat{\beta}_j)),$$

em que $Var(\hat{\beta}_j)$ é estimada através do correspondente termo da diagonal da matriz de covariâncias

$\hat{Var}(\hat{\beta}) = (\mathbf{X}'\hat{\mathbf{W}}\mathbf{X})^{-1} \hat{\phi}$. Vamos denotar por $ep(\hat{\beta}_j) = \sqrt{\hat{Var}(\hat{\beta}_j)}$ o erro padrão de $\hat{\beta}_j$.

- Embora possam ser aplicados ao teste de hipóteses de dois ou mais parâmetros, o uso mais frequente do teste de Wald contempla apenas um parâmetro por vez. Em situações envolvendo mais parâmetros, é mais usual aplicar o teste da razão de verossimilhanças.
- Considere então o seguinte par de hipóteses:

$$\begin{aligned} H_0 : \beta_j &= \beta_j^{(0)} \\ H_1 : \beta_j &\neq \beta_j^{(0)}, \end{aligned}$$

em que $\beta_j^{(0)}$ é algum valor postulado para β_j (é comum tomarmos $\beta_j^{(0)} = 0$, a fim de testarmos a nulidade de β_j). Então, o teste de Wald baseia-se na seguinte estatística-teste:

$$Z_t = \frac{\hat{\beta}_j - \beta_j^{(0)}}{ep(\hat{\beta}_j)},$$

que, sob a hipótese nula, tem assintoticamente distribuição Normal padrão.

- Para um nível de significância α , rejeitaremos H_0 caso $|Z_t| > z_{1-\alpha/2}$, em $z_{1-\alpha/2}$ representa o quantil $1-\alpha/2$ da distribuição Normal padrão.
- Nos casos em que ϕ é desconhecido, pode-se usar a distribuição *t-Student* com $n-p$ graus de liberdade, rejeitando H_0 , para um nível de significância α , se $|Z_t| > t_{n-p;1-\alpha/2}$.

No R: A estatística e o teste de Wald são apresentados no próprio `summary` de um MLG.

Nota – A função `waldtest`, do pacote `lmtest` permite aplicar o teste de Wald para hipóteses envolvendo $p \geq 2$ parâmetros, baseado numa distribuição assintótica χ^2_{n-p} .

Intervalos de confiança

- Dentre os métodos disponíveis para obtenção de intervalos de confiança em Modelos Lineares Generalizados, serão destacados os intervalos baseados na razão de verossimilhanças e na estatística de Wald. Mais adiante discutiremos o uso de simulação (bootstrap) para a obtenção dos intervalos.

Intervalos de confiança baseados na razão de verossimilhanças

- Um intervalo com nível de confiança assintótico $1-\alpha$ para β_j , baseado na razão de verossimilhanças, contém todos os valores $\beta_j^{(0)}$ para os quais a hipótese nula $H_0 : \beta_j = \beta_j^{(0)}$ não seria rejeitada pelo TRV, ao nível de significância α .

- Para fins de ilustração, considerando um nível de confiança (assintótico) de 95%, o intervalo de confiança para β_j conteria todo $\beta_j^{(0)}$ para o qual a hipótese $H_0 : \beta_j = \beta_j^{(0)}$ produzisse:

$$\xi_{RV} = \frac{D_0 - D_1}{\phi} = 2\phi^{-1} \left\{ \ln \left[\frac{L(\hat{\boldsymbol{\mu}}_1; \mathbf{y})}{L(\hat{\boldsymbol{\mu}}_0; \mathbf{y})} \right] \right\} \leq \chi_{0,95;1}^2 = 3,84,$$

sendo D_0 o desvio avaliado considerando $\beta_j = \beta_j^{(0)}$ e D_1 o desvio avaliado no modelo sem restrição para β_j .

No R: Função `confint`.

Intervalos de confiança baseados na estatística de Wald

- Uma vez que, assintoticamente:

$$\frac{\hat{\beta}_j - \beta_j}{ep(\hat{\beta}_j)} \sim Normal(0,1),$$

pode-se determinar quantis $z_{\alpha/2}$ e $z_{1-\alpha/2}$ tais que:

$$P\left(z_{\alpha/2} < \frac{\hat{\beta}_j - \beta_j}{ep(\hat{\beta}_j)} < z_{1-\alpha/2}\right) \approx 1 - \alpha, \quad 0 < \alpha < 1.$$

- Isolando β_j no centro da desigualdade, temos:

$$P\left(\hat{\beta}_j - z_{1-\alpha/2}ep(\hat{\beta}_j) < \beta_j < \hat{\beta}_j + z_{1-\alpha/2}ep(\hat{\beta}_j)\right) \approx 1 - \alpha.$$

- Assim, um intervalo de confiança $1 - \alpha$ (assintótico) para β_j fica dado por:

$$IC(\beta_j; 1 - \alpha) = (\hat{\beta}_j \pm z_{1-\alpha/2} ep(\hat{\beta}_j)).$$

No R: `confint.default(ajuste)`.

Intervalo de confiança para a resposta média em $\mathbf{x} = \mathbf{x}_0$

- A estimativa pontual da resposta média para um vetor de covariáveis $\mathbf{x}' = \mathbf{x}'_0 = (1, x_{01}, x_{02}, \dots, x_{0p-1})$, $\mu_0 = E[y | \mathbf{x}_0]$, baseada no ajuste de um modelo linear generalizado, é dada por:

$$\hat{\mu}_0 = g^{-1}(\mathbf{x}'_0 \hat{\boldsymbol{\beta}}),$$

onde g é a função de ligação do modelo e $\hat{\boldsymbol{\beta}}$ a estimativa de máxima verossimilhança de $\boldsymbol{\beta}$.

- Seja $\hat{\eta}_0 = \mathbf{x}'_0 \hat{\boldsymbol{\beta}}$ a estimativa do preditor linear calculada em \mathbf{x}_0 . A variância assintótica de $\hat{\eta}_0$ fica dada por:

$$Var(\hat{\eta}_0) = Var(\mathbf{x}'_0 \hat{\boldsymbol{\beta}}) = \mathbf{x}'_0 Var(\hat{\boldsymbol{\beta}}) \mathbf{x}_0.$$

- Como $\hat{\eta}_0 = \mathbf{x}'_0 \hat{\boldsymbol{\beta}}$ é uma combinação linear dos $\hat{\boldsymbol{\beta}}$'s, temos que, assintoticamente:

$$\hat{\eta}_0 \sim Normal(\mathbf{x}'_0 \boldsymbol{\beta}, \mathbf{x}'_0 Var(\hat{\boldsymbol{\beta}}) \mathbf{x}_0).$$

- Assim, um intervalo de confiança $1 - \alpha$ assintótico para $\eta_0 = \mathbf{x}'_0 \boldsymbol{\beta}$ fica dado por:

$$IC(\eta_0, 1 - \alpha) = \mathbf{x}'_0 \hat{\boldsymbol{\beta}} \pm z_{\alpha/2} \cdot \sqrt{(\mathbf{x}'_0 \hat{Var}(\hat{\boldsymbol{\beta}}) \mathbf{x}_0)},$$

sendo $z_{\alpha/2}$ o quantil $\alpha/2$ da distribuição Normal padrão. Apenas para efeito de notação, vamos representar o intervalo de confiança para η_0 por $(\eta_{0L}; \eta_{0U})$.

- Assim, um intervalo de confiança assintótico $1 - \alpha$ para μ_0 fica dado por:

$$IC(\mu_0, 1 - \alpha) = (g^{-1}(\eta_{0L}); g^{-1}(\eta_{0U})),$$

se g for estritamente crescente e

$$IC(\mu_0, 1 - \alpha) = (g^{-1}(\eta_{0U}); g^{-1}(\eta_{0L}))$$

se g for estritamente decrescente.

No R: `p1=predict(ajuste,type='link',newdata=x0,se.fit=T)`
 ### `x0` é um dataframe com os dados para os quais se quer estimar a resposta.
 ### O argumento `se.fit=T` é para retornar os erros padrões das estimativas.
`estimat=p1$fit`
`errpad=p1$se.fit`
`ic=exp(estimat+c(-1.96,1.96)*errpad)` ### Vale se a ligação for logarítmica.
 Se for outra, basta trocar `exp()` pela inversa da ligação usada.